

# Sistemas Multiagente em Smart Cities: Estado da Arte, Desafios e Tendências Futuras

Universidade do Minho  
Agentes e Sistemas Multiagente

**Abstract.** O conceito de *Smart Cities* é cada vez mais relevante em todo o mundo, impulsionado pela necessidade de melhorar a sustentabilidade, a eficiência dos serviços públicos e a qualidade de vida das populações. Neste contexto, os sistemas multiagente (SMA) surgem como uma abordagem promissora pelas suas arquiteturas distribuídas e eficientes e pela capacidade de se adaptarem a situações dinâmicas e complexas. Este trabalho tem como objetivo investigar o papel dos SMA no desenvolvimento e operação das *Smart Cities*, apresentando uma análise de algumas das suas aplicações, arquiteturas, desafios e tendências. Através de um estudo da literatura existente, são identificadas algumas áreas onde os SMA têm demonstrado maior impacto, incluindo transportes inteligentes, monitorização ambiental, planeamento urbano, etc. Além disso, são discutidas arquiteturas e *frameworks* usadas nas implementações, as principais características dos agentes como as suas tarefas e interação outros agentes e as maiores vantagens das propostas, bem como uma breve análise crítica. Por fim, são exploradas tendências futuras que vir a aparecer cada vez mais e apontam para o aumento da autonomia e capacidade de trabalho dos agentes passando pela integração com LLMs e por melhorias no desempenho e segurança dos agentes, reforçando o potencial dos sistemas multiagente como tecnologia chave para o futuro das *Smart Cities*.

**Keywords:** Sistemas Multiagente · Inteligência Artificial · Smart Cities · Mobilidade Inteligente · Sustentabilidade Ambiental

## 1 Definição do Domínio de Investigação

### 1.1 Smart Cities

As *Smart Cities* são um tema que tem vindo a suscitar bastante interesse por parte de governos, investigadores e indústrias de todo o mundo, dado que é expectável que 68% da população mundial viva em áreas urbanas até 2025 [1] e é necessário que as cidades sejam capazes de suportar o aumento da população e oferecer boa qualidade de vida. O conceito de uma cidade inteligente é central para o desenvolvimento dos países e tem como objetivo melhorar a qualidade de vida da população, promover a sustentabilidade e a gestão de recursos, utilizando conceitos tecnológicos como *IT* (*Information Technologies*), *IoT* (*Internet of Things*) e Inteligência Artificial [2], sendo este último de maior interesse no âmbito do estudo dos sistemas multiagente.

Esta área de investigação procura encontrar formas de automatizar e/ou otimizar várias áreas do contexto urbano como a mobilidade e os transportes, a gestão de energia e outros recursos, o ambiente, as infraestruturas digitais e edifícios, a economia e até as habitações dos cidadãos. Para além disso, também pode ajudar a uma melhor preparação dos serviços para responder a eventos inesperados como catástrofes naturais, acidentes ou emergências de saúde pública.

### **1.2 Sistemas Multiagente**

No desenvolvimento das *Smart Cities*, existem desafios relacionados à uma quantidade grande de dados e informação, possivelmente em tempo real, nos quais os sistemas de gestão centralizados tradicionais podem revelar-se insuficientes.

Para responder a estes problemas, os Sistemas multiagente procuram fornecer arquiteturas compostas por várias entidades capazes de tomar decisões autónomas, os agentes. Estes conseguem percecionar o ambiente que os rodeiam, tomar decisões, executar ações, comunicar e coordenar com outros agentes ou, possivelmente, com o exterior, disponibilizando uma interface [3].

De forma a perceber como estes sistemas podem ser integrados nas estruturas das *Smart Cities* e trazer precisamente a componente da inteligência, este documento visa reunir casos de estudo sobre aplicações em diversas áreas, para que seja feita uma análise das suas características e viabilidade num contexto amplo.

## **2 Metodologia de Investigação**

No processo de investigação da literatura, procuramos seguir o protocolo PRISMA (Preferred Reporting Items for Systematic Reviews and Meta-Analyses). A revisão focou-se em publicações sobre sistemas multiagente aplicados a Smart Cities. Durante este processo, utilizamos várias fontes para encontrar artigos tais como:

- IEEE Xplore
- ACM Digital Library
- Google Scholar
- SpringerLink

Começamos com os termos de pesquisa “smart city agent” e identificamos e juntamos cerca de 25 artigos, depois de selecionarmos aqueles que iam de encontro com o tema. De seguida, removemos alguns artigos que eram similares, diminuindo a amostra para 2. Com a leitura das introduções ficamos a perceber qual a proposta de cada artigo e assim excluímos cerca de 7, restando 15. Os que não se mostraram tão interessantes e com número elevado de páginas também eliminamos. Por fim, com a leitura dos artigos na íntegra ficamos a conhecer melhor as propostas e filtramos aqueles que continham mais detalhe na parte da arquitetura dos agentes e onde esta parte era realmente um foco importante, sobrando no final cerca de 8 casos para estudar.

### 3 Análise de Estado de Arte

#### 3.1 Mobilidade Inteligente

À medida que a população das cidades aumenta, cresce também o número de veículos em circulação, sendo cada vez mais difícil para sistemas tradicionais de regulação de trânsito gerir esta quantidade enorme de tráfego. É preciso adotar novas estratégias com sistemas mais inteligentes e assim surge o conceito de mobilidade inteligente, que se revela como uma nova abordagem inovadora, que recorre a tecnologias modernas, como inteligência artificial, sensores e sistemas de comunicação em tempo real para otimizar o fluxo do trânsito. É neste contexto que sistemas multiagente podem desempenhar um papel crucial, abordando o problema de forma distribuída e autónoma.

#### Monitorização e Regulação Inteligente do Trânsito Urbano

Dentro do contexto de mobilidade inteligente, a monitorização e regulação inteligente do trânsito surge como uma das áreas mais interessantes para a adoção de sistemas multiagente. Estes sistemas possibilitam a gestão descentralizada do fluxo de veículos, adaptando-se em tempo real às variações do trânsito, promovendo assim uma circulação mais fluída e sustentável.

Por exemplo, o sistema multiagente proposto por Zied Arbi et al. monitoriza continuamente o estado do trânsito e ajusta dinamicamente o tempo dos semáforos, conforme a densidade de veículos em cada interseção [4].

O sistema adota uma arquitetura distribuída que permite uma melhor escalabilidade do sistema em função do crescimento da cidade e é baseada na cooperação entre os agentes, características importantes para a sua aplicabilidade no mundo real. Envolve 3 tipos de agentes:

- *Road Intersection Agent* - responsável por ajustar o tempo dos semáforos conforme o número de veículos em cada interseção de modo a minimizar tempos de espera.
- *Traffic Generation Agent* - Na simulação, tem o papel de gerar o tráfego dinamicamente de modo a ser possível avaliar o sistema. No mundo real, responsável por agregar os dados recebidos pelos sensores, em tempo real, permitindo assim manter o número de veículos em cada interseção sempre atualizado.
- *Interface Agent* - responsável por assegurar o *launch* dos dois agentes anteriores. Permite ao administrador monitorizar o estado de cada agente e disponibiliza uma interface gráfica com o fluxo do trânsito, em tempo real, na cidade.

Todos estes possuem uma arquitetura reativa respondendo a estímulos sem recurso a uma representação interna do mundo. Eles que respondem diretamente às condições do ambiente sem recorrer a um raciocínio muito complexo, o que possibilita um ajuste mais rápido do tempo dos semáforos conforme o trânsito. Esta reatividade juntamente com as interações com os outros agentes, garante ao sistema a inteligência, respostas mais rápidas e uma eficiência operacional melhor.

### *Implementação*

A implementação do sistema foi realizada na plataforma JADE (Java Agent Development Framework), uma framework amplamente utilizada para o desenvolvimento de sistemas multiagente. O JADE é compatível com as especificações FIPA (Foundation for Intelligent Physical Agents), garantindo a interoperabilidade e a comunicação padronizada entre agentes através de mensagens ACL (Agent Communication Language). Esta framework fornece uma infraestrutura modular que permite criar, lançar e gerir agentes distribuídos de forma eficiente, sendo particularmente adequada para aplicações em cidades inteligentes, onde a escalabilidade e a comunicação em tempo real são essenciais.

### *Resultados e Limitações*

Os autores testaram este sistema com simulações, realizadas com dados gerados pelo *Traffic Generation Agent*. Os resultados demonstraram reduções significativas nos tempos médios de espera, melhorando a fluidez do trânsito. Também se observou que o modelo de comunicação entre agentes adjacentes apresentou um desempenho superior, especialmente em cenários de tráfego com distribuição irregular. Apesar dos resultados positivos, a abordagem apresenta algumas limitações. A validação foi realizada em ambiente de simulação com modelos de tráfego matemáticos, que podem não corresponder a todas as complexidades e correlações temporais do tráfego real. Para além disso, o modelo assume que todas as escolhas de rota dos veículos são equiprováveis, não assumindo fatores como a presença de pontos de interesse (como lojas, restaurantes), que acabam por influenciar as decisões dos condutores no mundo real. Por fim, falta mencionar que embora a comunicação entre agentes melhora o desempenho, este está sujeito a uma sobrecarga de comunicação na rede, que pode ser um fator crucial para implementações em larga escala e com uma densidade elevada.

### **3.2 Gestão de Crises**

As cidades modernas estão cada vez mais expostas a uma diversidade crescente de crises, desde acidentes rodoviários, desastres naturais ou emergências de saúde pública. Os sistemas tradicionais de gestão de crises são centralizados e com uma pesada hierarquia, o que resulta em tempos de resposta bastante elevados, alocação ineficiente de recursos e uma fraca adaptação aos eventos imprevistos.

A proposta investigada por G.Devadasu et al. é a criação de um sistema de gestão de crises descentralizado e adaptativo que busca transformar a cidade num ecossistema resiliente. Tem foco em abandonar modelos antigos e adotar uma nova abordagem proativa, onde os problemas conseguem ser antecipados e mitigados antes de sequer começarem [5].

Os objetivos principais desta abordagem são:

- Diminuir o tempo de resposta - Reduzir o tempo entre a deteção de um incidente e a ação realizada para resolver o mesmo.

- Otimizar a alocação de recursos - Garantir que os recursos de emergência sejam enviados para os sítios mais necessitados, da forma mais eficiente possível.
- Utilizar técnicas de inteligência artificial para prever potenciais crises com base na análise contínua de dados.

Para alcançar esta visão, é proposto um sistema multiagente com as seguintes características:

#### *Arquitetura do Sistema*

A sua arquitetura é descentralizada (Peer-to-Peer), cada agente opera de forma autónoma, mas está constantemente a comunicar com outros agentes de forma a alcançarem objetivos coletivamente.

#### *Frameworks e Tecnologias*

A abordagem para este projeto é denominada de “Multi-Agent Deep Learning”, onde cada agente é construído com base em *Deep Reinforcement Learning* (DRL), que permite aos agentes aprender e tomar decisões complexas em ambientes dinâmicos, sem precisar de supervisão. Para garantir a integridade, transparência e segurança na comunicação entre agentes, o sistema integra a tecnologia *Blockchain*, onde permite registar e validar cada decisão e troca de informação de forma resistente a manipulações, garantindo um histórico de auditoria fiável.

#### *Agentes do Sistema*

O sistema é composto por agentes cognitivos e proativos. Estes agentes possuem capacidades de raciocínio, planeamento e aprendizagem e conseguem modificar o seu próprio comportamento com base na experiência.

Este sistema não é focado em agentes com diversas funções, mas sim num único modelo de agente, cuja especialização depende do setor urbano que o representa. Cada agente monitoriza um domínio específico, como transportes, saúde ou segurança pública, com base nos dados que lhe são fornecidos.

É fundamentalmente um agente com capacidade de aprendizagem, onde utiliza *Deep Reinforcement Learning* para ajustar o seu comportamento com base na análise de cenários de crises passadas e em dados recebidos em tempo real. A principal função deste modelo é prever potenciais crises antes que estas aconteçam. Para tal, utiliza modelos de *Machine Learning*, incluindo redes neurais, para analisar padrões e antecipar os eventos.

#### *Resultados e Limitações*

A avaliação de desempenho do sistema proposto, demonstrou em ambiente de simulação uma superioridade significativa em relação aos sistemas de gestão de crises existentes. O sistema alcançou uma precisão de 91% na previsão de crises, superando largamente as abordagens tradicionais que existem atualmente, ao mesmo tempo que se mostrou 30% mais rápido no tempo de resposta a emergências. Adicionalmente, a tomada de decisão entre os agentes permitiu uma redução de 20% no desperdício de recursos durante a sua alocação.

Contudo, é crucial reconhecer as limitações desta abordagem. A sua eficácia depende do *Deep Reinforcement Learning*, que por sua vez exige uma elevada complexidade computacional e o acesso a grandes volumes de dados. Além disso, é importante notar que os resultados foram obtidos exclusivamente de cenários de simulação. A transição para um ambiente real introduziria imprevisibilidade dos fatores humanos, exigindo um processo de calibração complexo e um ajuste recorrente dos modelos de agentes. Esta implementação acarreta também um elevado custo, devido à sua infraestrutura complexa, como também levanta sérias preocupações relativas à privacidade e segurança no tratamento de dados sensíveis.

### **3.3 Planeamento Urbano**

O planeamento urbano é um tópico de interesse crescente na realidade atual. Os territórios são considerados sistemas complexos devido ao imenso conjunto de elementos que os constituem e colaboram para a sua expansão. Por isso, ao longo das últimas décadas, especialistas da área tem vindo a estudar as descontinuidades associadas à dificuldade de previsão, que muitas vezes resultam em não-linearidade e auto-organização das cidades.

Neste tema existem estudos que visam principalmente a introdução de sistemas multiagente para a análise do estado do solo (fatores naturais - erosão, propenso a inundações, etc.), do tipo de ocupação (ex.: residencial, comércio, indústria, etc.), das relações entre os agentes e da acessibilidade via meios de transporte. Devido à alta complexidade dos problemas, o estado atual dos estudos é mais voltado para simulações, tendo em conta variações nos pesos dos fatores.

#### **Simulador de Crescimento Urbano**

Para garantir o desenvolvimento sustentável das cidades modernas, é importante garantir um crescimento urbano adequado e saudável. O sistema multiagente proposto por André Bastos e Antônio Costa [6] visa justamente realizar isto por meio de um simulador, que, de forma muito simples permite manipular comportamentos e prever resultados.

O modelo da cidade proposto é populado por agentes que interagem entre si e mudam suas posições, para alcançar um estado de equilíbrio. Para este trabalho foram considerados um total de 4 tipos de agentes: industrial, comercial, residencial e um agente especial “Cidade”, usado para representar o “mundo”. Este último é também responsável por ler os mapas, gerar centróides, calcular as quantidades de agentes e probabilidades, gerar e posicionar cada agente, gerar o mapa final e calcular as estatísticas.

A parte de infra-estrutura (rodovias, ferrovias) também pertence ao ambiente da simulação, sendo representada em diferentes camadas, assim como os rios que cruzam a cidade e os usos de solo que não sofrem alteração relevante, como é o caso do institucional e áreas de lazer/recreação (áreas verdes).

#### *Tipos de Agentes*

Através de agentes reativos, o tipo mais simples, é possível modelar tarefas complexas, se usados da forma certa. Os agentes baseiam-se no que é percebido a cada instante, mas sem uma representação explícita do ambiente. Cada um deles tem objetivos individuais, que representam a categoria da qual fazem parte (por exemplo, ferrovias, rodovias, rios).

O agente “Cidade” é o único que se destaca por ser deliberativo, pois é este que controla, guarda o estado geral do modelo e efetua operações complexas.

#### *Arquitetura*

A arquitetura apoia-se no conceito de centróides, que servem como representantes de um grupo de agentes reativos. Esses centróides têm um peso maior ou menor conforme o tamanho do grupo que ele representa. O peso de cada um deles, por sua vez, deve ser atualizado a cada novo agente filho gerado pelo agente cidade que encontrou sua posição de equilíbrio. Os agentes são atraídos ou repelidos pelos centróides e pelas infraestruturas que compõem o ambiente, havendo com isso, a formação de vetores de força que passam a agir sobre esses agentes reativos. Após a criação de um novo agente, o mesmo passa a se deslocar pelo ambiente procurando atingir seu estado de equilíbrio dentro da sociedade, com base em uma série de regras específicas para cada tipo de agente.

#### *Resultados e Limitações*

Devido à dificuldade de obter dados reais de cidades de porte médio, optou-se por realizar a simulação utilizando apenas uma cidade como estudo de caso. Porém, isso não inviabiliza a utilização do simulador para outras cidades com características semelhantes à do teste.

Através de exercícios de simulação desse tipo é possível obter resultados satisfatórios, capazes de auxiliar no processo de tomada de decisões relativas à organização e planeamento de construções, ao mesmo tempo que possibilitam reduzir custos e riscos aplicáveis em situações reais.

No contexto deste trabalho o uso de SMA mostrou-se perfeitamente aplicável para a modelagem, permitindo a obtenção de resultados que encorajam o prosseguimento da pesquisa e o desenvolvimento de melhorias no protótipo em trabalhos futuros.

#### **3.4 Ambiente e Sustentabilidade Inteligente**

A sustentabilidade ambiental tem cada vez mais se destacado como preocupação central em várias sociedades. Com as alterações climáticas e as diversas consequências que estas trazem, tem se vindo a adotar posturas que minimizem o impacto ambiental e procurem a preservação dos recursos naturais.

Aqui, os sistemas multiagente também podem desempenhar um papel importante, ao oferecerem uma abordagem distribuída e inteligente para a análise e resolução de problemas relacionados com o meio ambiente.

#### **Monitorização da qualidade do ar**

E.G Dragomir propõe uma implementação de um sistema multiagente com o objetivo de analisar o Índice de Qualidade de Ar (IQA) e mostra como esta ferramenta pode ser usada na resolução de um dos principais problemas ambientais [7].

A medição da qualidade do ar é feita através do controlo de valores de poluentes atmosféricos e fatores meteorológicos, do seu armazenamento e posterior análise.

Para isso, é apresentada a arquitetura AQDMASv1, onde o sistema é dividido em 2 subsistemas: o subsistema de medições (SM, apenas presente a nível local) e o subsistema de análises (SA) e a estrutura de medição é distribuída geograficamente por 3 níveis.

#### *Nível local*

O agente no SM está conectado a sensores e inicia uma medição quando o agente coordenador faz esse pedido. Para além disso, deve apresentar um erro se um dos sensores estiver com problemas.

No SA, o agente é o coordenador da estação que é responsável por armazenar e analisar os valores medidos e gerar um relatório de qualidade local. Os resultados são depois enviados ao coordenador do nível regional.

#### *Nível regional*

Ao nível regional, há um agente coordenador que gere as informações recebidas das várias estações locais e com base nelas cria o relatório de qualidade regional em função dos pedidos que recebe do nível nacional.

Para além do coordenador, também está presente um agente de *Data mining* que tem a tarefa de com base nos dados que chegam à estação, construir um modelo para prever os valores de concentração de poluentes na respetiva região, integrando assim técnicas de *Machine learning* neste sistema disponíveis para o utilizador.

#### *Nível nacional*

Neste nível, o funcionamento é similar ao anterior. Existe um coordenador que calcula o IQA a nível nacional com base nas informações enviadas pelos agentes regionais e também um agente de *Data mining* que procura prever a evolução dos poluentes a nível nacional com base nos dados regionais.

#### *Arquitetura dos Agentes*

O único tipo de agente no SM possui uma arquitetura reativa, diferente dos demais, não registando uma representação do seu ambiente e tomando decisões apenas com base nos pedidos que recebe e no estado dos sensores a que está ligado.

Os restantes têm uma arquitetura deliberativa, guardam as regras relativas à geração dos relatórios de qualidade e também informações da estação como o instante de tempo ou o local e posteriormente desempenham as suas respetivas tarefas com base nisso.

Assim, os agentes organizam-se numa hierarquia e conseguem comunicar entre si enviado pedidos ou dados de forma a executarem as suas tarefas.

### *Implementação*

Neste caso de estudo, o sistema AQDMAv1 foi implementado de forma mais simples com 1 centro de monitorização regional e 6 locais, cobrindo a região de Ploiesti, uma cidade na Roménia.

Foi utilizada a *framework* ZEUS, seguindo os padrões FIPA e utilizando uma linguagem com protocolos de comunicação para agentes (FIPA-ACL), que executa numa *Java Virtual Machine*, assim como a Weka, usada para aplicar as técnicas de IA dos agentes de *Data Mining*. Com 22 parâmetros atmosféricos, foram criados 15 de 140 possíveis agentes (22 parâmetros \* 6 estações + 1 coordenador local \* 6 estações + 1 coordenador regional + 1 agente de *data mining*).

Foi possível verificar que os agentes comunicaram entre si para pedir as informações que necessitavam (cerca de 27% das mensagens) e para enviar essas mesmas informações (a maioria, com 61%) de forma autónoma e rápida.

### **Purificação do ar**

Indo um pouco mais além, Sahai et al. propõem um sistema que, para além de fazer uma monitorização do IQA, também inclui um mecanismo de purificação do ar [8].

Esta abordagem procura oferecer uma solução de purificação eficaz, tendo em conta a otimização do consumo de energia, onde as unidades de purificação são ativadas apenas quando os níveis de poluição o justificam e uma garantia da escalabilidade e robustez, onde o sistema possa crescer com a cidade.

A arquitetura proposta assenta num sistema multiagente denominado SAPAS (Swarm Air Purification Agent System). Este possui 3 pilares principais:

- *Clustering* (K-means): Utilizado na fase de planeamento, este algoritmo determina as localizações ideais para a instalação física dos agentes purificadores, garantindo uma cobertura otimizada da área e maximizando a eficiência do sistema.
- *Artificial Bee Colony* (ABC): Algoritmo inspirado no forrageamento das abelhas, e é utilizado para determinar qual a unidade de purificação a ativar, com base na avaliação do *fitness value* de cada local, que indica o potencial de melhoria de qualidade do ar.
- *Parâmetros de Percepção e Ação*: Estes são mecanismos que ligam os agentes ao mundo real. A percepção é realizada através do cálculo do IQA em tempo real por cada agente. A ação corresponde à ativação dos atuadores para intervirem diretamente no ambiente.

Os agentes que compõem o sistema operam sobre uma rede *peer-to-peer*, de forma a poderem comunicar-se diretamente uns com os outros para a partilha de informação

### *Agentes*

No SAPAS, os agentes são divididos da seguinte forma:

- Agente de Purificação do Ar (APA)

Cada agente destes possui 2 sensores: um para recolha de amostras de ar e outro para executar o mecanismo de purificação do ar. Eles são capazes de comunicação com outros agentes de forma a alcançar uma decisão.

Um destes agentes é designado o Agente Primário (AP1) que tem capacidade de processamento e tomada de decisão principais. Inicialmente é formado um grupo constituído por um Agente Primário e pelos APAs próximos. Depois, recebe os valores dos IQAs calculados pelos APAs e processa a informação e encontra uma solução ótima e é responsável por enviar uma mensagem de ativação da purificação para o APA selecionado e partilhar essa decisão com os restantes.

- Agentes Lógicos do Algoritmo ABC

Estes não são agentes físicos, mas sim papéis lógicos dentro do AP1 para executar a metodologia de otimização e dividem-se em 3 tipos:

► Scout Agent: A função deste agente é analisar todos os dados recebidos para identificar as áreas com os maiores níveis de poluição.

► Recruited Agent: Executa após o Scout Agent encontrar uma área que precise de atenção e a sua função é refinar a busca nos vizinhos, onde verifica se existe uma solução ainda mais eficiente.

► Random Agent: Este agente é responsável por gerar soluções aleatórias para evitar que o algoritmo não fique preso numa solução boa mas não ótima.

Apesar de não ser referido no artigo original, podemos considerar que todos os agentes têm uma arquitetura reativa, não armazenando uma representação do mundo e realizando as tarefas em função dos respetivos estímulos, exceto o Agente Primário que adota uma arquitetura deliberativa pois precisa de tomar decisões com base no estado que tem guardado de forma a coordenar o seu grupo e a desempenhar as suas tarefas.

### Avaliação

Numa área que é bastante exaustiva e ineficiente com os métodos tradicionais, como a monitorização e análise de valores em massa, a grande vantagem é a autonomia dos vários agentes que, depois de serem corretamente configurados, ficam devidamente organizados e sabem quais são as suas tarefas e interações que precisam de executar e a partir daí sabem o que fazer em cada situação sem intervenção humana, trazendo uma grande eficiência para o processo.

No caso de estudo de monitorização da qualidade do ar, para automatizar ainda mais o processo, podem ser feitas melhorias nos pontos que isso ainda não se verifica, como lidar com falhas dos sensores de medição e atribuir capacidades aos agentes coordenadores para analisar os relatórios gerados e tomar ações como emitir alertas, tanto para as pessoas responsáveis pela análise como para a população nas cidades, em caso de valores perigosos, e a integração com serviços de meteorologia de forma automática, por exemplo.

No sentido contrário, a outra proposta na mesma área, apesar de usar técnicas inovadoras e de realmente atuar no mundo físico ao purificar o ar, aparenta ser mais incompleto. O estudo não apresenta nenhuma implementação onde especifique alguma *framework* e protocolo de comunicação para visualizarmos os resultados numa situação prática e também possui algumas lacunas como na definição das tarefas de cada agente ou no método de seleção de um Agente Primário, mas ainda assim tem potencial.

## 4 Conclusões Adquiridas

### 4.1 Análise Crítica

É possível concluir que os sistemas multiagente têm um potencial enorme e devem ser considerados como ferramentas em diversas áreas para construir soluções para os desafios que surgem no desenvolvimento das cidades ou para melhorar as existentes e tornar as infraestruturas existentes mais inteligentes.

Entre as propostas analisadas, existem umas mais promissoras que outras e que poderiam ser mais viáveis de implementar no mundo real.

O problema do trânsito nas cidades é cada vez maior e uma simples solução de controlo dos semáforos inteligente pode significar melhorias nos tempos de espera. A proposta apresentada anteriormente é relativamente simples e poderia levar mais aspetos em conta como a presença de peões em espera para atravessar, mas ainda assim conseguiria um bom desempenho na tarefa. A principal dificuldade aqui é que muitas vezes a causa do trânsito é simplesmente o número elevado de carros, logo a motivação para implementar um sistema de semáforos inteligente pode não ser muito elevada na maioria das situações.

Na área do planeamento urbano, a utilização de sistemas multiagente mostra-se promissora para os casos em que seja complexo encontrar a melhor organização para os terrenos de forma tradicional. Assim, com a evolução e melhoria dos sistemas, estes podem vir a ser uma ferramenta útil que otimize processos neste campo.

No que diz respeito à gestão de crises, esta abordagem destaca-se pelo seu potencial em aumentar a adaptação urbana, pela sua capacidade em reagir e também em prever crises através de uma aprendizagem contínua. Contudo, esta proposta enfrenta barreiras significativas à sua implementação no mundo real. A sua eficácia depende de tecnologias que exigem um custo de implementação e uma complexidade computacional consideráveis. Adicionalmente, a necessidade de agregar e processar em tempo real volumes de dados enormes, levanta questões críticas de privacidade e segurança, dado que o sistema tem de lidar com informações sensíveis. Embora o seu potencial de ter um grande impacto no meio urbano, a sua viabilidade acaba por ser limitada, dado à sua complexidade de implementação no mesmo.

Quanto à aplicação na monitorização do ar, foi possível verificar que estes sistemas podem ser integrados nas infraestruturas de análise ambiental. A adoção

de um sistema deste género no mundo real à partida seria fácil, já que podem ser instalados em estações de controlo ambiental já na rede. No primeiro caso, verificou-se que estava definida uma hierarquia entre níveis das estações que, apesar de ser esperado que se verifique na maioria das situações, pode ser um entrave à integração.

#### 4.2 Tendências Futuras

Os sistemas multiagente em *Smart Cities* encontram-se numa encruzilhada tecnológica, com múltiplas tendências emergentes que irão moldar o seu futuro desenvolvimento [2]. Este capítulo sistematiza as principais direções de investigação e desenvolvimento identificadas na literatura científica contemporânea.

##### **Agentes Inteligentes Baseados em Large Language Models (LLMs)**

- **Contexto e Motivação**

A integração de *Large Language Models* em sistemas multiagente constitui uma das tendências mais significativas atualmente [9–11]. Analogamente aos agentes tradicionais que utilizam lógica simbólica ou aprendizagem clássica, os agentes baseados em LLMs conseguem compreender linguagem natural, raciocinar sobre contextos complexos e comunicar com utilizadores humanos de forma intuitiva [9, 10].

- **Características de Sistemas multiagente com LLMs**

Os sistemas LLM-MAS (LLM-based Multi-Agent Systems) utilizam especialização: cada agente LLM assume um papel específico numa equipa, em vez de um único modelo tentar resolver tudo [9, 11]. Por exemplo, numa *Smart City*, um agente pode especializar-se em análise de dados de tráfego, enquanto outro se concentra em gestão energética, e um terceiro em resposta a emergências. Estes agentes comunicam através de linguagem natural, permitindo coordenação dinâmica sem necessidade de protocolos fixos [10, 11].

A pesquisa mostra que sistemas multiagente com LLMs demonstram maior precisão através de validação cruzada: múltiplos agentes verificam resultados uns dos outros, reduzindo alucinações e erros [9]. Estudos indicam melhorias de até 40% em tarefas complexas comparadas com LLMs isolados [9].

- **Desafios Técnicos**

Os principais desafios residem em latência (LLMs implicam um grande investimento monetário) e custos de inferência [10, 11]. Em Smart Cities, aplicações críticas como resposta a emergências requerem respostas em milissegundos, enquanto LLMs requerem segundos ou mais [10]. Adicionalmente, as alucinações de LLMs continuam a ser problema, requerendo validação cuidada de outputs [10, 11].

- **Tendências Emergentes**

Agentes LLM mais pequenos e especializados para domínios urbanos específicos estão a emergir [9, 10]. Combinações de LLMs com raciocínio simbólico (neuro-simbólico) prometem balancear flexibilidade de LLMs com garantias de lógica clássica [10, 11] e modelos de LLM que executam localmente em dispositivos edge (fora da parte central de uma rede, onde dados são gerados ou consumidos [12]) ganham cada vez mais destaque para preservar a questão da privacidade [10].

### **Blockchain e Tecnologias de Ledger Distribuído para Confiança**

- **Necessidade de Confiança em Sistemas Autónomos**

Os MAS descentralizados enfrentam desafios fundamentais de confiança [13–15]. Daí surgem algumas questões:

1. Como garantir que agentes não mentem sobre dados que fornecem?
2. Como garantir que transações entre agentes são executadas atomicamente sem intermediário?
3. Como manter registo imutável de decisões para auditoria e conformidade?

O *Blockchain* oferece uma solução para todos estes desafios através de um registo distribuído imutável onde todas as transações são encriptadas. Uma vez que a transação é gravada em *Blockchain*, esta não pode ser alterada retroativamente sem consenso da maioria da rede [13, 14].

- **Aplicação de Blockchain em Dados Urbanos**

O *KnowLedger* é sistema desenvolvido por investigadores da Universidade do Minho, que demonstra como o *Blockchain* pode ser operado inteiramente por agentes, formando um sistema multiagente. O sistema implementa *multi-chain* onde diferentes tipos de dados (clima, poluição, tráfego, energia) têm “chains” separadas para otimizar performance [13, 15].

Neste sistema existem agentes designados de *workers* que recolhem dados da fonte original (sensores IoT, bases de dados municipais) e que os pré-processam. Os agentes *Ledger* criam transações, validam e realizam mineração dos blocos, mantendo consenso da *Blockchain*. O mecanismo inovador é denominado de *Proof-of-Confidence*: em vez de requerer processamento computacional intensivo (Proof-of-Work) ou *stake* monetário (Proof-of-Stake), o sistema recompensa agentes que historicamente forneceram dados precisos e confiáveis [13, 15].

- **Limitações atuais**

Apesar do potencial, o *Blockchain* convencional tem limitações críticas para Smart Cities, nomeadamente no que toca a velocidade [13–15]. Numa cidade inteligente,

onde milhões de transações podem ser efetuadas numa pequena de fração de segundos, isto é, naturalmente, inadequado [13, 14].

O consumo energético também acaba por ser problemático, uma vez que o *Proof-of-Work* que é uma mecanismo de consenso requer uma enorme quantidade de energia computacional. Isto é ecologicamente insustentável para sistemas que pretendem tornar cidades mais verdes e sustentáveis.

Para resolver estes problemas, estão a emergir *Blockchains* otimizadas para IoT e Smart Cities. IOTA é uma tecnologia de registo distribuído (DLT) que se destaca por não usar a *Blockchain* tradicional, mas sim uma estrutura chamada “Tangle”, um grafo acíclico dirigido (DAG) ao invés de *Blockchain* linear, permitindo paralelização e velocidade muito superior[14, 15].

## References

1. Department of Economic and Social Affairs, U.N.: 68% of the world population projected to live in urban areas by 2050, says UN, <https://www.un.org/uk/desa/68-world-population-projected-live-urban-areas-2050-says-un>, acedido 2025/10/30.
2. Arora, A., Jain, A., Yadav, D., Hassija, V., Chamola, V., Sikdar, B.: Next Generation of Multi-Agent Driven Smart City Applications and Research Paradigms. IEEE Open Journal of the Communications Society. (2023). <https://doi.org/10.1109/OJCOMS.2023.3310528>.
3. Wooldridge, M.J.: An introduction to multiagent systems. John Wiley & Sons (2002).
4. Arbi, Z., Belkahla Driss, O., Sbai, M.K.: A Multi-Agent System for Monitoring and Regulating Road Traffic in a Smart City. Em: International Conference on Smart, Monitored and Controlled Cities (2017). <https://doi.org/10.1109/SM2C.2017.8071843>.
5. Devadasu, G., Nagarjuna, T., Sarika, S., Balassem, Z., Dyana, S., Anakath, A.S.: Enhancing Crisis Management in Smart Cities: A Multi-Agent Deep Learning Approach forredictive and Adaptive Urban Resilience. IEEE Open Journal of the Communications Society. (2024). <https://doi.org/10.1109/ICMCTC62214.2025.11196621>.
6. Bastos, A.D., Rocha Costa, A.C. da: SimCidade – Um simulador de crescimento urbano utilizando Sistemas Multiagentes Reativos. (2007).
7. Dragomir, E.G.: A multi-agent system for monitoring and analyzing the air quality index. Environmental Engineering and Management Journal. 18, (2019).
8. Sahai, P., Kumar, R., Mehrotra, M.: Bee Swarm Intelligence Inspired Sustainable Swarm Air Purification Agent System with K-means Clustering. SN Computer Science. (2025). <https://doi.org/10.1007/s42979-025-04033-x>.
9. Jimenez-Romero, C., Yegenoglu, A., Blum, C.: Multi-Agent Systems Powered by Large Language Models: Applications in Swarm Intelligence, (2023). <https://doi.org/10.48550/arXiv.2503.03800>.
10. SuperAnnotate: Multi-agent LLMs in 2025, <https://www.superannotate.com/blog/multi-agent-llms>, acedido 2025/11/01.
11. Xue-Guang: LLMs for Multi-Agent Cooperation, <https://xue-guang.com/post/llm-marl/>, acedido 2025/11/01.
12. Microsoft Azure: O que é a computação edge?, <https://azure.microsoft.com/pt-pt/resources/cloud-computing-dictionary/what-is-edge-computing>, acedido 2025/11/02.
13. Fernandes, B., Diogo, A., Silva, F., Neves, J., Analide, C.: KnowLedger - A Multi-Agent System Blockchain for Smart Cities Data. Em: AAMAS (2022). <https://doi.org/10.5555/3535850.3536144>.

14. Anthony Jnr, B.: Artificial intelligence of things and distributed technologies for smart cities. *Internet of Things*. 28, (2024). <https://doi.org/10.1016/j.iot.2024.101399>.
15. ACM Conference: Smart Cities Powered by Blockchain: Building the Foundation. Em: *Proceedings of the 2025 Conference* (2025).