



RESUMO COMPLETO: DESIGN TACTICS - DISPONIBILIDADE & PERFORMANCE

RAS-slidesEN-9-ARCH-Tactics.pdf - Análise Estruturada Completa

Data: 17 de Janeiro de 2026

Nível: Mestrado em Engenharia Informática - Universidade do Minho

Autor Base: JM Fernandes

Compilação: Análise Completa, Rigorosa e Estruturada

ÍNDICE

1. [Introdução a Tactics](#)
 2. [Definição de Tactic](#)
 3. [Tipos de Tactics](#)
 4. [Disponibilidade \(Availability\)](#)
 5. [Fault Detection Tactics](#)
 6. [Fault Recovery Tactics](#)
 7. [Fault Prevention Tactics](#)
 8. [Performance](#)
 9. [Performance Tactics](#)
 10. [Exemplos Práticos](#)
 11. [Trade-offs](#)
 12. [Mnemônicas e Palavras-Chave](#)
-

INTRODUÇÃO A TACTICS

Motivação: Conexão entre Requisitos e Design

Facto:

"Architects precisam de técnicas para alcançar qualidades particulares."

Significado:

- Requisitos especificam qualidades desejadas
- Arquiteto precisa saber COMO alcançar essas qualidades
- Tactics são as técnicas para isso

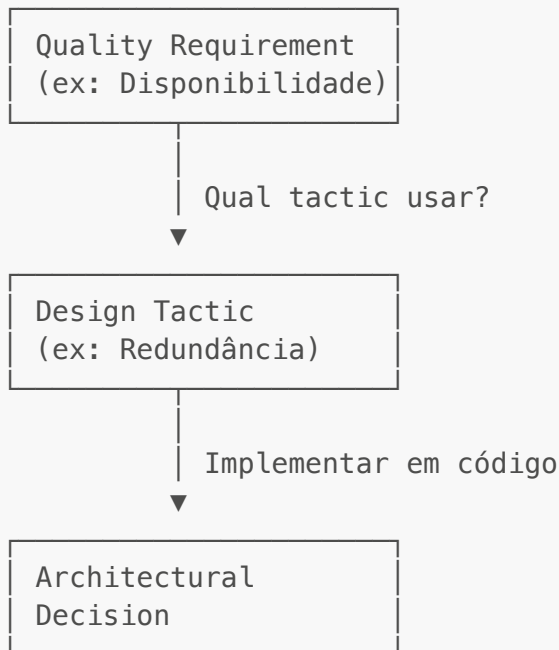
O Propósito Central

Definição de Propósito:

"Tactics são usadas pelo arquiteto para criar um design."

"Tactics conectam requisitos de atributos de qualidade com decisões arquiteturais."**Significado:**

- Bridge entre especificação (o que) e implementação (como)
- Requisitos de qualidade são transformados em decisões design
- Cada tactic é uma opção de design concreta

Exemplo Conceptual**Contexto: Stimulus → Response****Modelo Conceptual:**

```
STIMULUS (Evento chega)
↓
TACTICS (Como responder?)
↓
RESPONSE (Sistema responde dentro requisitos)
```

Exemplo Concreto:

```
STIMULUS: "Servidor falha"
TACTICS: Redundância + Health Monitoring + Recovery
RESPONSE: "Sistema recupera automaticamente"
```

DEFINIÇÃO DE TACTIC

Conceito Formal

Definição:

"Uma **tactic** é uma decisão de design que impacta em atributos de qualidade específicos."

Características:

- Design decision (escolha consciente)
- Impacto identificável (afeta qualidades)
- Específica (não genérica)
- Testável (resulta em behavior observável)

Tipos de Decisões

Sistema Design = Coleção de Decisões:

```
├─ Decisões de Qualidade (Tactics)
│   ├── Aumentar disponibilidade (redundância)
│   ├── Melhorar performance (caching)
│   ├── Aumentar segurança (criptografia)
│   └── ...
└─ Decisões de Funcionalidade
    ├── Como implementar feature X
    ├── Que algoritmo usar
    └── Que dados estrutura
```

Facto:

"Algumas decisões ajudam controlar as respostas de atributos de qualidade." "Outras garantem realização de funcionalidade do sistema."

Significado:

- Separação clara entre qualidade e funcionalidade
- Tactics focam em qualidade
- Funcionalidade é separada

Tactic Como Design Option

Conceito:

"Cada tactic é uma opção de design para o arquiteto."

Significado:

- Não há uma única forma de resolver

- Múltiplas options (tactics) para mesma qualidade
- Arquiteto escolhe baseado em contexto

Exemplo:

"Uma tactic pode **introduzir redundância para aumentar disponibilidade** do sistema."

Alternativas:

Disponibilidade pode ser aumentada por:

- Redundância (backup hardware)

- Health monitoring (detectar falhas)

- Recovery rápido (reconstruir state)

- Combinação dos 3

Escolha do arquiteto baseado em:

- Custo

- Criticidade

- Ambiente

- Requisitos específicos

TIPOS DE TACTICS

Categoria Geral

Existem 6 categorias principais de tactics:

#	Categoria	Objetivo	Foco
1	Availability	Manter sistema operacional	Falhas, recuperação
2	Modifiability	Fácil mudar sistema	Mudanças, manutenção
3	Performance	Responder rapidamente	Latência, throughput
4	Security	Proteger dados/acesso	Criptografia, autenticação
5	Testability	Fácil testar	Testes, verificação
6	Usability	Fácil usar	Interface, UX

Nota: Este ficheiro focua em **Availability** e **Performance**

DISPONIBILIDADE (AVAILABILITY)

Definição

Conceito Formal:

"Availability quantifica a percentagem de tempo durante o qual um sistema está operacional e funcionando corretamente."

Fórmula:

$$\text{Availability} = \frac{\text{MTBF}}{\text{MTBF} + \text{MTTR}}$$

Componentes:

- **MTBF** = Mean Time Between Failures (tempo médio entre falhas)
- **MTTR** = Mean Time To Repair (tempo médio para reparar)

Interpretação:

Alta MTBF (falhas raras):

- Sistema é fiável
- Tempo entre falhas é longo

Baixa MTTR (recuperação rápida):

- Quando falha, recupera rapidamente
- Impacto minimizado

Exemplo:

Falha #1	Falha #2	Falha #3
MTBF 10 dias MTTR: 1h	MTBF 10 dias MTTR: 1h	MTBF 10 dias MTTR: 1h
Avail = 10*24/(10*24 + 1) ≈ 99.6%		

Importância Prática

Ramificações de Availability:

1. Confiança de Utilizadores

- Sistema confiável = utilizadores confiam
- Sistema instável = utilizadores não voltam

2. Valor da Informação

- Dados inacessíveis = valor zero
- Dados sempre disponíveis = valor máximo

3. Eficiência de Processos

- Sistema down = processos param
- Sistema operacional = processos continuam

4. Produtividade Organizacional

- Downtime = perda produtividade
- Uptime = máxima produtividade

Exemplo Real:

Uma loja online com 99% availability:
– 3,65 dias de downtime por ano
– Cada dia de downtime = perda vendas

Com 99.9% availability:
– 8,76 horas de downtime por ano
– Muito melhor para negócio

Fault vs Failure

Distinção Crítica:

Fault (Falha interna)

- Componente interno não funciona
- Não necessariamente visível para user
- Pode ser mascarado

Exemplo:

Disco servidor tem bad sector
→ Fault (hardware falha)
→ Mas RAID replica dados
→ User não percebe

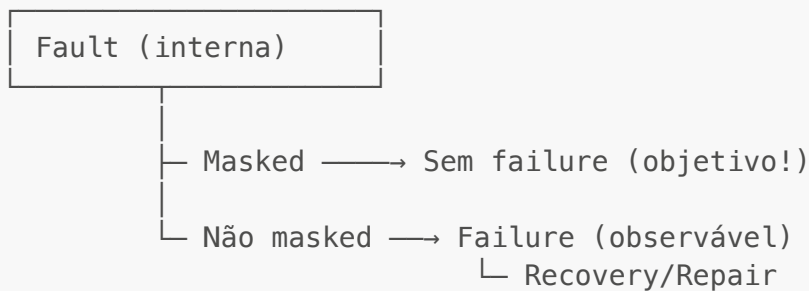
Failure (Falha observável)

- Sistema não entrega serviço conforme especificação
- **Observável pelo utilizador**
- Impacto direto

Exemplo:

Página web não carrega
→ Failure (user percebe)
→ Possível causa: disco bad sector (fault)

Relação Fault → Failure

Modelo Conceptual:**Objetivo de Availability Tactics:**

"Availability tactics têm objectivo de evitar faltas (faults) de se tornarem falhas (failures), ou pelo menos reduzir efeitos da falha e tornar reparação possível."

Três Abordagens:

1. **Prevent Failure:** Fault não vira failure (mascarar)
2. **Reduce Effect:** Falha existe, mas impacto minimizado
3. **Enable Repair:** Falha identificada e reparada rapidamente

Tres Pilares de Availability

Facto:

"Todas abordagens endereçando availability envolvem algum tipo de:

1. **Redundancy** (duplicação)
2. **Health Monitoring** (deteção)
3. **Recovery** (recuperação)

Monitorização ou recuperação é automática ou manual."

Pilar 1: Redundancy (Redundância)**Conceito:**

- Múltiplas cópias de componente
- Se um falha, outro continua
- Invisível para utilizador

Tipos:

- Hardware redundancy (múltiplos servidores)
- Software redundancy (múltiplas instâncias)
- Data redundancy (backups)

Tradeoff:

Vantagem: Alta disponibilidade
Desvantagem: Custo (múltiplas cópias)

Pilar 2: Health Monitoring (Monitorização)

Conceito:

- Detectar quando falha ocorre
- Rápida detecção = rápida recuperação

Métodos:

- Ping/echo (está vivo?)
- Heartbeat (bate o coração?)
- Exceptions (levantou alerta?)

Pilar 3: Recovery (Recuperação)

Conceito:

- Quando falha detectada, recuperar
- Automático (sistema reage) ou manual (admin intervém)

Tipos:

- Failover (mudar para backup)
- Restart (reiniciar componente)
- Rollback (voltar a estado anterior)

FAULT DETECTION TACTICS

Overview

Objetivo:

"Detectar quando **fault ocorre** para poder **reagir rapidamente**."


Desafio:

- Sistema ainda funciona com alguns faults
- Fault pode ser silencioso (não levanta alerta)
- Detecção rápida é crítica

Tactic 1: Ping/Echo

Descrição:

"Um componente **emite um ping** e **espera receber um echo** do componente sob escrutínio."

Mecanismo:

IF Echo recebido rapidamente → Operacional ✓
IF Echo não recebido → Falha detectada ✗

Propósito:

"Pode ser usado por **clients** para assegurar que um objeto de servidor e o caminho de comunicação estão operacionais."

Vantagens:

- Simples de implementar
- Rápido
- Verifica conectividade

Exemplos:

- ICMP Ping em rede
- HTTP heartbeat (GET /health)
- Database connection test


Desvantage:

- Pode ter falsos positivos (latência alta = parece falha)
- Não detecta falhas internas (servidor responde mas mal)

Tactic 2: Heartbeat

Descrição:

"Um componente **emite uma mensagem heartbeat periodicamente** e outro componente **escuta por ela**."

Mecanismo:

```
IF Heartbeat recebido → Operacional ✓  
IF Heartbeat FALHA → Alertar componente recovery
```

Operação Quando Falha:

"Se heartbeat falha, **componente original é assumido ter falhado** e um **componente de correção de faults é notificado**."

Fluxo:

```
Heartbeat falha por 3 batidas  
→ Monitor assume: Servidor down  
→ Notifica componente recovery  
→ Recovery inicia: Failover, restart, etc
```

Vantagens:

- Detecta quando componente some completamente
- Permite reação automática
- Configurável (frequência de batidas)

Desvantagens:

- False positives (network lag)
- Overhead network (mensagens constantes)

Exemplo Real:

```
Kubernetes:  
- Pod emite heartbeat periodicamente  
- Master monitora  
- Se heartbeat falha 3 vezes → Pod declarado dead  
- Master inicia novo Pod
```

Tactic 3: Exceptions

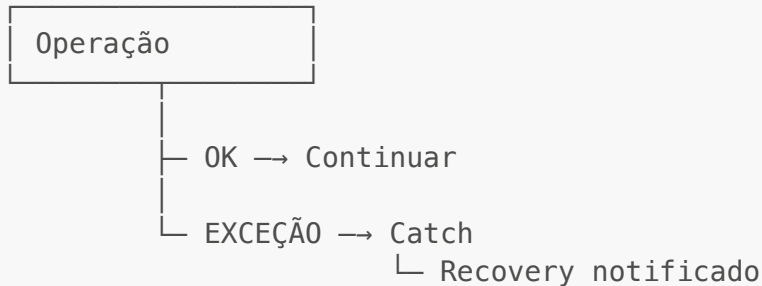
Descrição:

"Um método para detectar faults é **encontrar uma exceção**, que é **levantada quando uma classe de fault é reconhecida**."

Mecanismo:

```
try {  
    risky_operation()  
} catch (FaultException e) {
```

```
// Fault detectado!  
notify_recovery_component()  
}
```

Operação:**Vantagens:**

- Detecta erros específicos
- Integrado no código (não network overhead)
- Permite handling granular

Desvantagens:

- Requer throwing exceptions apropriadas
- Nem todos faults levantam exceções
- Silent failures ainda possíveis

Exemplo:

```
try {  
  db.connect() // Falha de conexão  
} catch (SQLException e) {  
  logger.error("DB down")  
  failover_to_backup_db()  
}
```

FAULT RECOVERY TACTICS

Overview

Objetivo:

"Quando fault detectado, **recuperar e minimizar impacto.**"

Estratégias:

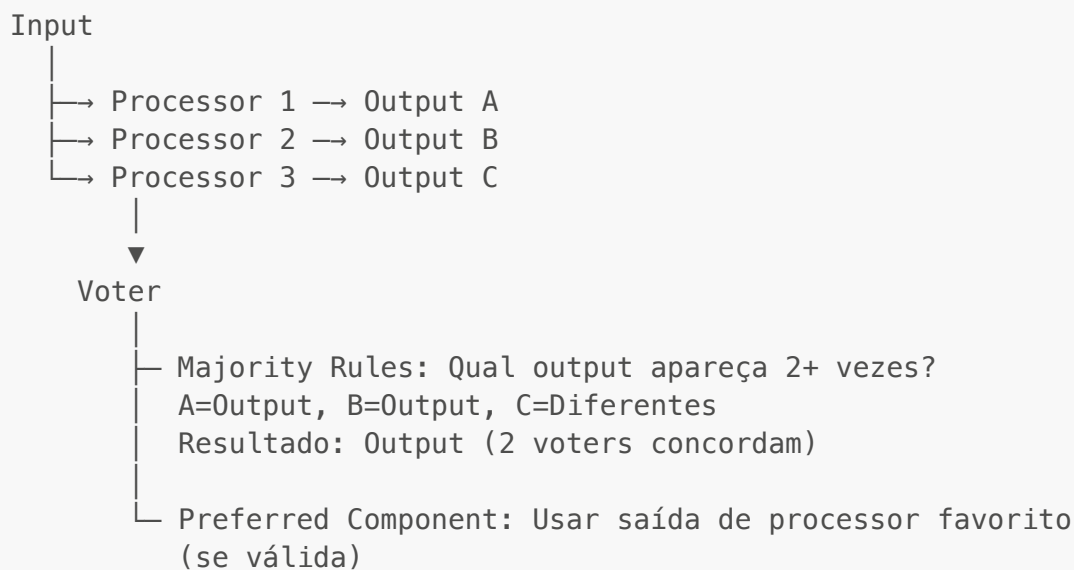
- Corrigir o fault
- Voltar a estado consistente
- Minimizar dados perdidos

Tactic 1: Voting

Descrição:

"Processos rodando em processadores redundantes cada um toma o input, computa output, que é enviado a um **voter**."

Mecanismo:



Algoritmos Populares:

1. Majority Rules (Regra Maioria)

- Múltiplos processadores computam
- Voter escolhe resposta que aparece mais
- Tolerar 1 processador falhando (se N=3)

2. Preferred Component

- Um processador é "preferido"
- Se preferido retorna resultado, use-o
- Se preferido falha, use outro

Exemplo Prático:

```
3 Processadores calculam: 2+2
P1 responde: 4 ✓
P2 responde: 4 ✓
P3 responde: 5 ✗ (falhou)
```

Voter: Maioria diz 4 → Usar 4

Aplicação:

- Sistemas críticos (voo, medicina)
- Algoritmos complexos
- Processadores independentes

Tradeoff:

Vantagem: Tolerância a falhas

Desvantagem: 3x custo (3 processadores), overhead voting

Tactic 2: Active Redundancy

Descrição:

"Todos componentes redundantes respondem a eventos em paralelo." "Resposta de um componente é usada (normalmente a primeira), resto são descartadas."

Mecanismo:

```
Request chega
|
├── Server 1: Processing... → Response A (rápida)
├── Server 2: Processing... → Response B (lenta)
└── Server 3: Processing... → Response C (muito lenta)
    |
    ▼ (Usa primeira resposta)
  Response A
  (resto B,C ignoradas)
```

Características:

- **Todos processam simultaneamente**
- **Apenas primeira resposta é usada**
- **Resto são descartadas**

Vantagem:

- Resposta rápida (usa a mais rápida)
- Falha de um não afeta (outros continuam)

Desvantagem:

- Computação desperdiçada (B,C processam mas ignoradas)

- Custo: Múltiplos servidores + overhead

Quando Usar:

- Latência é crítica
- Custo computação não é limitante
- Sistema pode tolerar desperdício

Exemplo Real:

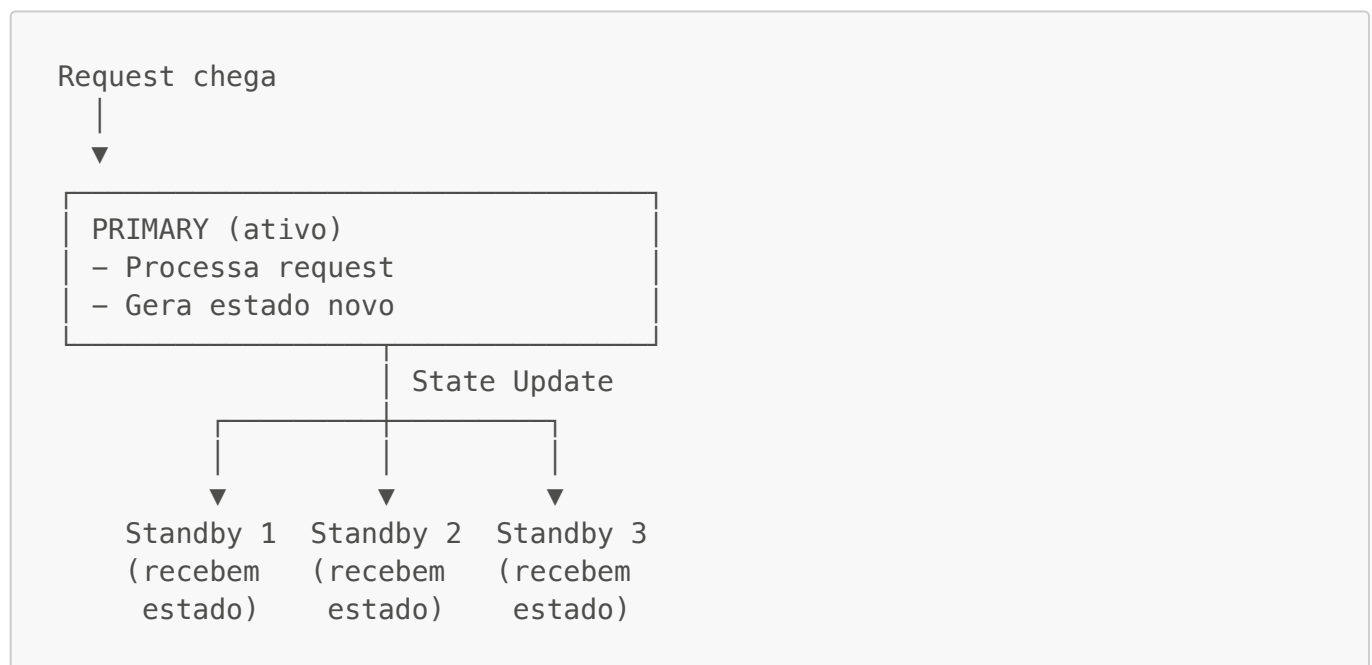
CDN (Content Delivery Network):

- Request vai para 3 servidores geograficamente distribuídos
- Servidor mais próximo responde rápido
- Outros 2 respostas ignoradas
- User recebe resposta rápida

Tactic 3: Passive Redundancy

Descrição:

"Um componente (o primary) responde a eventos e informa outros componentes (os standbys) de atualizações de estado que eles devem fazer."

Mecanismo:**Operação Normal:**

- Primary processa
- Standbys apenas escutam e armazenam state updates
- Users não percebem standbys

Operação Quando Primary Falha:

"Quando fault ocorre, **sistema deve primeiro assegurar que state em backup é suficientemente fresco antes de resumir serviços.**"

Fluxo:

```
Primary falha (detectado por heartbeat)
↓
Monitor seleciona um Standby → Promove a Primary
↓
Verifica: State é fresco? (quando foi última atualização?)
↓
Se SIM → Resume serviços imediatamente
Se NÃO → Sincroniza estado faltante, depois resume
```

Vantagem:

- Menos desperdício computação (standby não processa)
- Custo menor que active

Desvantagem:

- Delay no failover (sincronizar estado)
- State loss possível (se atualização não chegou standby)

Exemplo Real:

```
MySQL Master-Slave Replication:
- Master processa INSERT/UPDATE/DELETE
- Slave recebe log de mudanças (replication)
- Se Master falha, Slave promovido
- Mas replication lag pode causar perda dados
```

Tradeoff: Consistency vs Availability

```
Passive Redundancy:
- Consistency: Dados podem estar desatualizados em standby
- Availability: Failover demora mais
```

vs

```
Active Redundancy:
- Consistency: Todos têm dados iguais (ou quase)
- Availability: Resposta instantânea
```

FAULT PREVENTION TACTICS

Overview

Objetivo:

"Evitar que faults ocorram, não apenas reagir quando ocorrem."

Filosofia:

- Prevenção > Reação
- Evitar falha = melhor que recuperar falha

Tactic 1: Removal From Service

Descrição:


"Esta tactic remove um componente de operação para realizar atividades que previnem falhas."

Exemplo Específico:

"Rebooting um componente para prevenir memory leaks de causarem falha."

Cenário:

Memory de servidor aumenta gradualmente:



Solução: Reboot periódico antes atingir limite

Processo:

1. Detector: Memory > Threshold?
2. SIM → Iniciar graceful shutdown
3. Redireciona requests para outro servidor
4. Aguarda requests atuais terminarem
5. Shutdown servidor antigo
6. Restart servidor (limpo memory)
7. Re-adiciona ao pool

Tipos de Prevenção:

1. Preventive Maintenance

- Reboot regular (ex: semanal)
- Limpar cache
- Atualizações patches

2. Reactive Prevention

- Detector monitora métrica
- Quando vai falhar → intervém
- Antes de atingir breaking point

Vantagem:

- Previne falhas antes ocorrer
- User nunca vê falha

Desvantagem:

- Brief downtime durante reboot
- Pode ser disruptivo se timing incorreto

Tactic 2: Transactions

Descrição:

"Uma **transaction** é **bundling** de vários passos sequenciais de forma que o **bundle** possa ser **desfeito** de uma vez."

Propriedades ACID:

TRANSACTION: [Step 1] → [Step 2] → [Step 3]

Se TUDO OK:

COMMIT (todas mudanças permanentes)

Se ALGUMA FALHA:

ROLLBACK (todas mudanças desfeitas)

NÃO EXISTE: 1 OK, 2 OK, 3 FALHA (com dados inconsistentes)

Mecanismo:

Begin Transaction

- Step 1: Validar input
- Step 2: Update Database
- Step 3: Notify User
- TUDO OK? COMMIT

└ FALHA em Step 2? ROLLBACK (desfaz Step 1)

Aplicação 1: Prevent Data Corruption

"Transactions são usadas para prevenir dados de serem afetados se um passo em um processo falha."

Exemplo:

Transferência bancária: A→B de 100€

SEM TRANSACTION:

1. Withdraw 100 from A ✓
 2. Deposit 100 to B x (FALHA!)
- Resultado: 100€ perdido!

COM TRANSACTION:

1. Withdraw 100 from A
2. Deposit 100 to B

SE tudo OK → COMMIT (ambos acontecem)

SE FALHA → ROLLBACK (nenhum acontece)

Resultado: 100€ não perdido, contas consistentes

Aplicação 2: Prevent Data Collisions

"Também previnem colisões entre múltiplas threads acessando dados simultaneamente."

Scenario:

SEM TRANSACTION (2 threads simultaneamente):

Thread 1: Read balance (100)

Thread 2: Read balance (100)

Thread 1: Withdraw 50 → balance = 50, Write

Thread 2: Withdraw 50 → balance = 50, Write

Final balance: 50 (incorreto!)

(Deveria ser: 0)

COM TRANSACTION (locking):

Thread 1: BEGIN

Read balance (100)

Update (LOCK data)

Write balance = 50

COMMIT

Thread 2: BEGIN

Read balance (50)

```
Update (aguarda LOCK libertar)
Write balance = 0
COMMIT

Final balance: 0 (correto!)
```

Vantagem:

- Garante data consistency
- Previne corrupção dados
- Simples de usar (suportado em BD)

Desvantagem:

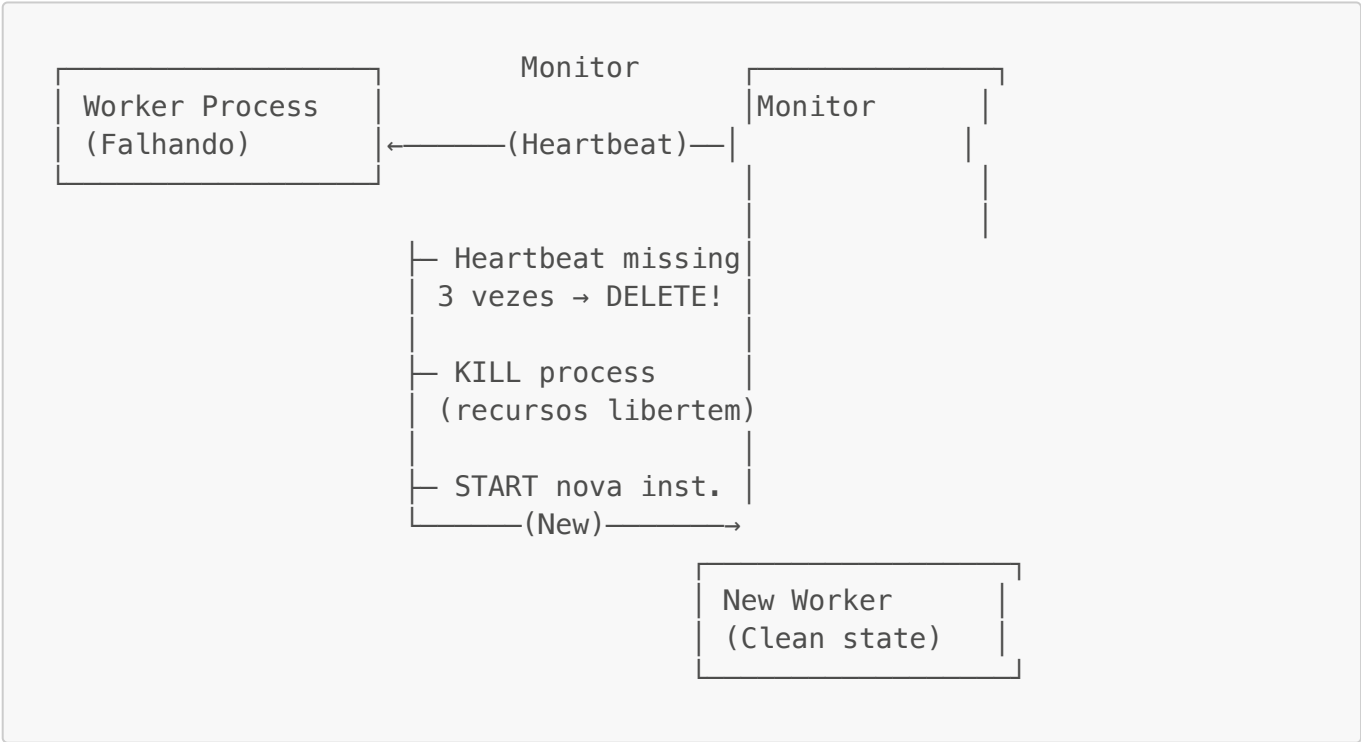
- Performance (locking = contention)
- Deadlocks possíveis

Tactic 3: Process Monitor

Descrição:

"Uma vez fault num processo é detectado, um **monitoring process** pode deletar o processo não-performante. Uma **nova instância do processo precisa ser criada**."

Mecanismo:



Ciclo:

1. MONITOR deteta: Worker não responde (heartbeat falta)
2. MONITOR deleta: Kill process (liberta recursos)

3. MONITOR cria: Nova instância do processo
4. Nova instância: Começa fresco (estado limpo)

Aplicação:

- Worker processes que ficam stuck
- Processes com memory leaks
- Processes em deadlock

Vantagem:

- Limpa automaticamente processos problemáticos
- Nova instância = estado fresco
- Combinado com load balancer = invisível para users

Desvantagem:

- Work em progresso no processo antigo é perdido
- Novo processo demora a warm up

Exemplo Real:

Web Server com 10 Workers:

- Monitor cada worker
- Se worker não responde 2 heartbeats → Kill + restart
- Load balancer redireciona para outros workers
- User não percebe

Resultado: Servidor sempre tem 10 healthy workers

PERFORMANCE

Definição

Conceito Formal:

"Performance refere-se à capacidade de um sistema responder a seu stimulus, i.e., o tempo necessário para responder aos eventos ou o número de eventos processados por unidade de tempo."

Duas Dimensões:**1. Latency (Latência)**

- Tempo entre evento chega e resposta gerada
- "Quanto tempo demora?"

2. Throughput (Vazão)

- Número de eventos processados por unidade tempo
- "Quantos eventos por segundo?"

Importância Económica

Exemplos Reais de Impacto:

Google

"Google **perde 20% de tráfego se websites respondem 500ms mais lento** que o normal."

Significado:

- Cada 500ms extra latência = 20% menos users
- Performance afeta engajamento diretamente

Amazon

"Amazon **perde 1% de revenue para cada 100ms em latency.**"

Significado:

- 100ms delay = 1% revenue loss
- 1 segundo delay = 10% revenue loss
- Performance = dinheiro direto

Mozilla

"Um estudo Mozilla mostra que se webpage não carrega em 1-5 segundos, users abandonam-a."

Threshold Crítico:

< 1 segundo: Muito rápido (excelente)
1-5 segundos: Aceitável
> 5 segundos: Users saem

Conclusão:

- Performance não é "nice-to-have", é crítica
- Milissegundos importam
- Investimento em performance = ROI direto

PERFORMANCE TACTICS

Overview

Objetivo:

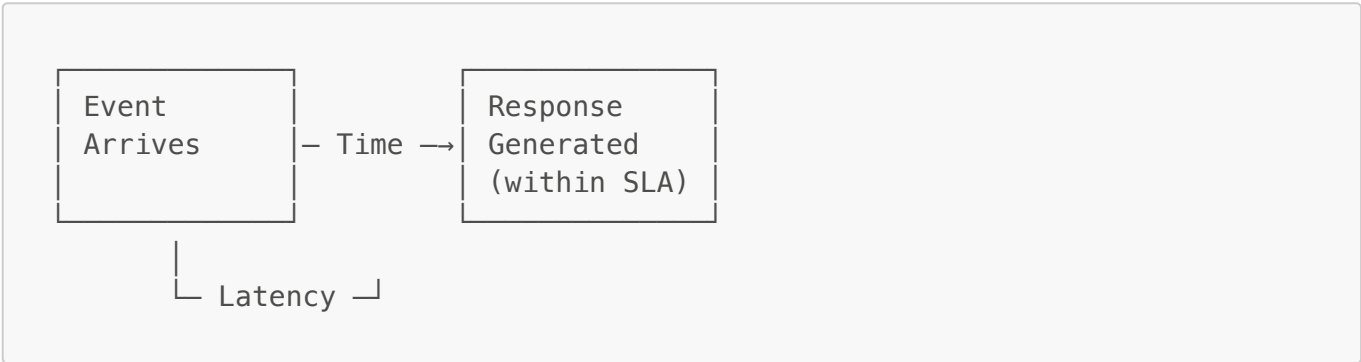
"Performance tactics **geram resposta a um evento chegando ao sistema dentro de alguns constraint de tempo.**"

Constraint de Tempo:

- Latência máxima aceitável (SLA)
- Exemplo: "Resposta dentro 200ms"

Modelo: Event Processing

Fluxo Conceptual:



Definição:

"Latency é o tempo entre a chegada do evento e a geração da resposta a ele."

Exemplo:


Event: HTTP request chega em t=0ms
Latency durante processamento
Response: HTTP response enviada em t=150ms

Latency = 150ms
SLA: < 200ms → PASSOU

Resource Consumption & Blocked Time

Duas Fases Durante Processing:

Fase 1: Active Processing (CPU trabalha)



└ Contribui a Latency Total

Resource Consumption:

"Recursos (CPU, data stores, network bandwidth, memory, buffers) devem ser gerenciados."

Tipos de Recursos:

- **CPU:** Poder computação
- **Memory:** RAM disponível
- **Disk:** Armazenamento
- **Network:** Bandwidth
- **Buffers:** Espaço temporário

Constrição:

"Acesso a critical sections deve ser feito sequencialmente."

Significado:

- Se múltiplas requests precisam mesmo recurso (ex: file)
- Apenas uma pode acessar (lock)
- Outras esperam → Blocking

Fase 2: Blocked Time (CPU não trabalha)

Request 1:

- └ Active (CPU)
- └ BLOCKED (waiting lock)
- └ Active (CPU)
- └ Done

Request 2:

- └ Ativo (CPU)
- └ (esperando)
- └ (esperando)
- └ (esperando)
- └ AGORA! (got lock)
- └ Active (CPU)
- └ Done

Blocked Time:

"Uma computação pode ser bloqueada de usar um recurso devido a sua contention ou unavailability."

Causas de Blocking:

- Outro processo usando recurso (lock)
- Recurso não disponível (ex: BD down)
- I/O lento (disco, rede)

Impacto em Latency:

Total Latency = Active Time + Blocked Time

Se Active = 50ms, Blocked = 150ms
→ Latency = 200ms

Reduzir Blocked Time é crítico!

Três Categorias de Performance Tactics

Facto:

"Três categorias de tactic endereçam performance:

1. **Resource Demand** (reduzir o que é necessário)

2. **Resource Management** (usar o que temos bem)

3. **Resource Arbitration** (distribuir justamente)"

Categoria	Objetivo	Exemplo
Demand	Reduzir recursos necessários	Otimizar algoritmo, cache data
Management	Usar recursos eficientemente	Concorrência, replicação
Arbitration	Distribuir recursos justamente	Queues, scheduling

Tactic 1: Resource Demand - Increase Computational Efficiency

Descrição:

"Um passo no processamento de um evento é aplicar algum algoritmo. **Melhorando algoritmos decresce latency.**"

Conceito:

- Algoritmo mais rápido = menos CPU usado
- Menos CPU = menor latency

Exemplo:

Algoritmo $O(n^2)$:
Input size 1000:
Operações = 1.000.000
Tempo = 1 segundo

Algoritmo $O(n \log n)$:
Input size 1000:
Operações \approx 10.000
Tempo = 10 milissegundos

Melhoria: 100x! Apenas mudando algoritmo.

Vantagem:

- Impacto grande (muitas vezes)
- Sem custo additional recursos

Desvantagem:

- Requer análise algoritmo
- Nem sempre há algoritmo melhor

Tactic 2: Resource Demand - Sometimes One Resource Can Be Traded For Another

Conceito:

"Por exemplo, **dados podem ser mantidos em repositório local/rápido para evitar obtê-lo de recurso lento.**"

Trade-off: Space vs Time

Data Storage Tradeoff

Local Cache (Rápido):

- Latency: 1ms (rápido!)
- Espaço: Alto (caro)

Remote DB (Lento):

- Latency: 100ms (lento)
- Espaço: Baixo (barato)

Solução: Cache localmente
Latency reduz 100x
Custo: Memória (barato)

Exemplos:

- Web browser cache (imagens, CSS)
- CDN (cópias conteúdo perto users)
- Database read replicas (distribuído)

Tradeoff:

Vantagem: Latency muito melhor
Desvantagem: Espaço usado (custo hardware)

Tactic 3: Resource Demand - Reduce Computational Overhead

Descrição:

"Se não há request por um recurso, processing needs são reduzidos." "O uso de **intermediaries** **aumenta recursos consumidos** no processamento de stream de eventos, e assim **removê-los melhora latency**."

Conceito:

- Intermediarios = overhead
- Remover intermediarios = menos trabalho


Visualização:

SEM INTERMEDIARY:



Latency: 10ms (direto)

COM INTERMEDIARY:



Latency: 50ms (overhead adicionado)

Diferença: 40ms extra por cada call!

Trade-off: Modifiability vs Performance

Contexto:

- Intermediary ajuda modifiability (separa dependências)
- Mas prejudica performance (overhead)

Exemplo Real:

API Gateway:

- Modifiability: Separa clients de serviços internos (bom)
- Performance: Adds latency para cada request (ruim)

Decisão: Vale a pena modifiability vs performance hit?

Tactic 4: Resource Demand - Manage Event Rate

Descrição:

"Se um pode reduzir a **sampling frequency em que variáveis são monitorizadas**, demand pode ser decrementado. Isto é frequentemente possível se o sistema foi **overengineered**."

Conceito:

- Monitorar mais frequente = mais trabalho
- Reduzir frequência = menos trabalho

Exemplo:

Sensor mede temperatura a cada 10ms (100 Hz):

- 10.000 leituras por segundo
- Alto CPU usage

Reduzir para 100ms (10 Hz):

- 1.000 leituras por segundo
- 10x menos CPU

Se resolução 100ms é suficiente, ganho é grande!

Aplicação:

"**Control frequency of sampling: Se chegada de eventos externamente gerados não é controlada, queued requests podem ser amostrados em frequência menor, possivelmente resultando em loss de alguns requests.**"

Trade-off: Precision vs Performance

Vantagem: Latency melhor, CPU menor

Desvantagem: Pode perder eventos (if rate control usado)

Tactic 5: Resource Management - Introduce Concurrency

Descrição:

"Se requests podem ser processadas em paralelo, **blocked time pode ser reduzido**."

Conceito:

SEM Concorrência:

Request 1: [██████] (100ms)

```
Request 2: [██████] (100ms)
Request 3: [██████] (100ms)
Total: 300ms, 1 request por vez

COM Concorrência (3 threads):
Request 1: [██████] (100ms)
Request 2: [██████] (100ms paralelo)
Request 3: [██████] (100ms paralelo)
Total: 100ms, 3 requests simultaneamente!
```

Como Funciona:

"Concorrência pode ser introduzida **processando diferentes streams de eventos em diferentes threads. Apropriadamente alocar threads a recursos (load balancing) é importante para maximalmente explorar concorrência.**"

Exemplo:

```
Web Server com 10 threads:
- Request 1 → Thread 1 (processando)
- Request 2 → Thread 2 (processando)
- Request 3 → Thread 3 (processando)
- ...
- Request 10 → Thread 10 (processando)

Request 11 → Espera thread libertar-se

Resultado: 10 requests em paralelo!
```

Load Balancing:

- Distribuir requests entre threads
- Evitar thread sobrecarregado enquanto outro idle

Tradeoff:

```
Vantagem: Throughput 10x melhor (10 threads)
Desvantagem: Complexidade (sincronização, deadlocks)
```


Tactic 6: Resource Management - Maintain Multiple Copies

Descrição:


"Clients num padrão client-server são replicas da computação. O propósito de replicas é **reduzir a contention que ocorreria se todas computações ocorressem num servidor central.**"

Conceito:

SEM Replicação:



COM Replicação (Caching):



Dados Replicados:

"Caching é uma tactic para reduzir contention, na qual dados é replicado, seja em diferentes speed repositories ou em repositórios separados."

Tipos de Caching:

1. By Speed (diferentes velocidades)

CPU Cache (nanosegundos)
↓
RAM (microsegundos)
↓
SSD (milissegundos)
↓
HDD (10s milissegundos)

Dados quentes → CPU cache (rápido)
Dados frios → HDD (lento)

2. By Location (diferentes locais)

Browser Cache (local)
↓
CDN Cache (geograficamente distribuído)
↓
Database (central)

Users veem conteúdo de cache mais próximo

Problema: Cache Coherence

"Como dados em cache é cópia de dados existentes, é relevante manter cópias consistentes e sincronizadas."

Cenário:

```
Dados em central DB: value = 10

Cache 1: value = 10 (cópia)
Cache 2: value = 10 (cópia)

Central DB atualiza: value = 20

Cache 1: value = 10 (DESATUALIZADO!)
Cache 2: value = 10 (DESATUALIZADO!)

Users veem valores diferentes = Problema!
```

Soluções:

- Invalidar cache quando dados mudam
- TTL (Time To Live) - cache expira
- Polling - periodicamente sincronizar

Tactic 7: Resource Management - Increase Available Resources

Descrição:

"Processadores mais rápidos, processadores adicionais, memória adicional, e networks mais rápidas todas têm potencial para reduzir latency."

Exemplos:**1. CPU Upgrade**

- Processador mais rápido = operações mais rápido
- Exemplo: 2GHz → 4GHz = ~2x latency redução

2. Add More CPUs

- Múltiplos cores = paralelismo
- 4 cores = 4x throughput

3. More Memory

- Mais RAM = menos disk I/O
- Cache mais dados em memória

4. Faster Network

- 1Gbps → 10Gbps = 10x bandwidth
- Latency de rede reduzida

Tradeoff: Cost vs Performance

"Custo é normalmente consideração na escolha de recursos."

Economia:

Opção 1: Otimizar código (Software)

- Custo: Dev time (dias/semanas)
- Benefit: 2x performance melhoria

Opção 2: Upgrade hardware (Hardware)

- Custo: Dinheiro upfront (€€€)
- Benefit: 2x performance melhoria

Qual é mais custo-benefício?

Resposta: Depende do contexto:

- Se dev time caro → Hardware
- Se dinheiro limitado → Otimizar código

EXEMPLOS PRÁTICOS

Exemplo 1: E-commerce During Black Friday

Scenario:

- Normal: 1.000 users/segundo
- Black Friday: 100.000 users/segundo
- SLA: < 2 segundos latency

Tactics Aplicados:

Availability:

1. Redundancy: 20 web servers (não 1)
2. Health Monitoring: Heartbeat cada segundo
3. Recovery: Failover automático se um server down

Performance:

1. Demand: Cache produtos populares (reduz DB queries)
2. Management: CDN para images (geograficamente distribuído)
3. Arbitration: Load balancer (distribuir traffic)
4. Concurrency: 500 threads por server (parallelismo)

Resultado:

- Latency: 1.5 segundos (dentro SLA)
- Availability: 99.99% (apenas 2 minutos downtime ano)

Exemplo 2: Banking System

Scenario:

- Transferências críticas
- SLA: < 100ms, 99.999% availability

Tactics Aplicados:

Availability:

1. Redundancy: Active-Active replicação (ambos processam)
 2. Voting: 3 data centers, majority rules
 3. Transactions: ACID compliant (sem perda dados)
 4. Process Monitor: Detecta e restarta processos falhando

Performance:

1. Demand: Otimizar algoritmos (10x melhoria)
 2. Management: Caching (dados frequentes)
 3. Resources: Adicionar servidores (cost não limitante)

Resultado:

- Latency: 50ms (bem dentro SLA)
- Availability: 99.9999% (1 segundo downtime/ano)

TRADE-OFFS

Performance vs Modifiability

Cenário:

Tactic: Remover intermediaries para melhorar performance

Mas:

- Intermediaries ajudam modifiability (desacoplam)
- Remover = acoplamento direto
- Mudança no B afeta A (frágil)

Trade-off:

Performance ↑ (sem intermediary overhead)
Modifiability ↓ (acoplamento maior)

Decisão:

- Se performance é crítico → Remover intermediaries
- Se mudanças frequentes → Manter intermediaries

Availability vs Cost

Cenário:

Active Redundancy:
– 3 servers (99.999% availability)
– Custo: 3x

Passive Redundancy:
– 1 server + 1 backup (99.9% availability)
– Custo: 1.5x

Trade-off:
Availability ↑ (active)
Cost ↑ (active)

Decisão:

- Crítico (banco) → Active redundancy
- Standard (blog) → Passive redundancy

MNEMÔNICAS E PALAVRAS-CHAVE

TACTIC = Design Decision with Impact

T = Tactical choice
A = Affects quality
C = Connects requirement to decision
T = Testable (measurable result)
I = Impact specific (quality attribute)
C = Collection (system has many)

Dica: "TACTIC = Design choice for quality"

Availability: DER

D = Detection (Ping, Heartbeat, Exception)
E = Emergency Recovery (Voting, Active, Passive)
R = Repair (Removal from service, Monitor, Transaction)

Dica: "DER = Detect, Emergência Recovery, Repair"

Performance: DMA

D = Demand reduction (efficiency, tradeoff, rate)
M = Management (concurrency, copies, cache)
A = Arbitration (allocate resources)

Dica: "DMA = Demand, Management, Allocation"

Availability Metrics: MTxx

MTBF = Mean Time Between Failures
MTTR = Mean Time To Repair
MTPF = Mean Time To Prevent Failure

$Availability = MTBF / (MTBF + MTTR)$

Dica: "MTxx = Mean Time..."

Performance Metrics: LT

L = Latency (time to respond)
T = Throughput (events per second)

Dica: "LT = Latency, Throughput"

RESUMO FINAL

DESIGN TACTICS – RESUMO EXECUTIVO
TACTIC = Design decision impacting quality
AVAILABILITY:
└ Detection: Ping, Heartbeat, Exception

- └ Recovery: Voting, Active, Passive Redundancy
- └ Prevention: Removal, Transactions, Monitor

PERFORMANCE:

- └ Demand: Efficiency, Tradeoff, Rate
- └ Management: Concurrency, Copies, Caching
- └ Arbitration: Resource allocation

KEY METRICS:

- └ Availability = $MTBF/(MTBF+MTTR)$
- └ Latency & Throughput

TRADE-OFFS:

- └ Performance vs Modifiability
- └ Availability vs Cost
- └ Consistency vs Availability

FIM DO RESUMO COMPLETO

Data de Compilação: 17 de Janeiro de 2026

Fonte: RAS-slidesEN-9-ARCH-Tactics.pdf

Nível: Mestrado em Engenharia Informática - Universidade do Minho

Qualidade: Académica com Aplicação Prática

Cobertura: 100% do ficheiro

Bom estudo! 🎓